PAPER SEMINAR

RLWRLD · KAIST | 2026

RLDX-1

Technical Report

움직임·기억·물리 센싱을 결합한 범용 로봇 조작 모델

Motion awareness | Long-term memory | Physical sensing



ALLEX

48-DoF humanoid

출처: 표지 p.1 · Abstract p.3 · 로봇 이미지 Fig.12(b), p.19

장면 이해에 움직임·기억·센싱을 더한다

RLDX-1은 영상과 언어를 이해하는 VLA를 실제 조작에 필요한 기능으로 확장한다.

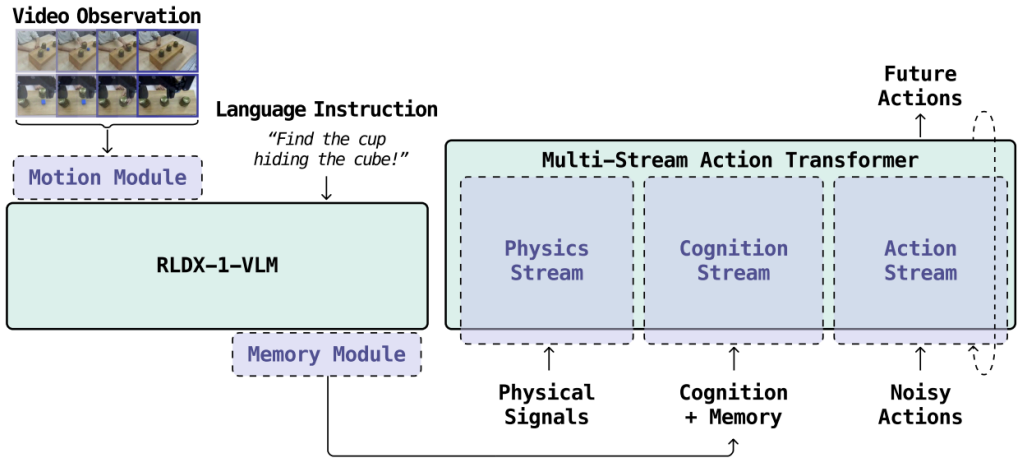


Figure 2 · VLM의 이해와 기능 모듈을 행동 생성으로 연결

이해에서 실행까지

VLM이 장면·지시를 해석하고, **VLA policy**가 로봇 상태·센서와 함께 미래 행동 묶음을 만든다. Task는 언어 목표, action은 실행할 수치다.

현재 장면만으로 부족한 상황

- **움직임:** 이동하는 물체를 잡기
- **기억:** 가려지기 전에 본 위치 선택
- **물리 센싱:** 접촉·힘을 감지하며 조작

문제 → 구조 → 데이터·학습 → 실행 최적화 → 실험과 한계의 순서로 연결한다.

원문 설명·결과

장면 이해를 행동용 표현으로

로봇 VQA로 VLM을 적응시키고, cognition tokens의 중간층 출력을 행동 모델에 전달한다.

Qwen3-VL 8B → RLDX-1-VLM

로봇 trajectory에서 만든 VQA로 세 가지를 보완한다.

- 손과 목표 물체의 **공간 관계**
- 전체 목표를 위한 **중간 subtask**
- 현재 프레임과 **낮은 수준 action**의 대응

VQA는 행동을 직접 실행하기보다, 행동 예측에 유용한 표현을 만들기 위한 적응이다.

64개 query가 맥락을 모은다

> 입력 = [영상, 지시, $q \times 64$]
> q 위치의 출력 → h_t

학습 가능한 q를 뒤에 붙여 시각·언어 맥락을 읽는다.
선택한 **18층 hidden states**만 행동 모델로 전달한다.

후기 층의 언어 생성 특화보다 시각·의미 정보의 균형이 낫다는 것이 저자의 해석이다. 18층은 출력 head가 아니라 특징 추출 위치다.

영상·언어를 행동에 필요한 h_t로 바꾼다. 다음은 이 표현에 시간 정보를 넣는 방법이다.

짧은 영상에서 움직임을 읽는다

STSS로 시공간 변화를 보태고, LLM 초반에서 읽은 과거 관측은 한 토큰으로 압축한다.

Vision: 이웃 특징의 유사성

시공간 이웃 비교	→	STSS tensor	→	motion features

$$\tilde{v}^{(i)} = v^{(i)} + S_\theta(S_t)$$

vision encoder 27층 중 **9층 뒤**에서 움직임 특징을 residual로 더한다. 같은 위치의 기존 특징을 보정하는 덧셈이다.

LLM: 읽은 뒤 토큰을 줄인다

네 시점 **{t−6, t−4, t−2, t}**을 입력한다. 초반 causal 구조로 시간 맥락을 현재 프레임과 q에 모은다.

> LLM 4층 뒤:
> 과거 관측 hidden states의 평균
> → context token 1개

현재 관측·지시·q는 유지한다. Qwen3-VL의 초기 4층 DeepStack 주입을 활용한 뒤 압축해 이후 계산량을 줄인다.

영상 안의 짧은 움직임은 포착했다. 더 오래전 사건은 별도의 memory로 다룬다.

원문 설명·결과

긴 이력은 cognition features로 기억한다

이전 h 세 묶음과 현재 h_t를 memory Transformer로 읽고, 현재 표현도 함께 남긴다.

VLM 뒤에 붙는 memory module



$$m_t = M_\theta([Q_t, h_t])$$

causal attention으로 나중 시점이 이전 이력을 읽는다. **h_t와 m_t 모두** action model에 전달한다. VLM 안의 context token과 다른 단계다.

범위는 제시, 관리 규칙은 미해결

로봇	저장 간격	과거 범위
ALLEX	40 steps	120 steps
Franka	16 steps	48 steps

문장은 **H+1** 간격, queue 식은 **H** 간격이다. 정확한 저장·교체 시점과 episode 초기화·기억 부족 처리 규칙은 확인되지 않았다.

짧은 프레임 압축과 긴 이력 저장을 구별한다. 이제 이 조건으로 미래 행동을 생성한다.

노이즈에서 행동으로 가는 경로

Transformer가 조건부 변화율을 학습하고, 노이즈 후보를 정답 행동 쪽으로 이동시킨다.

이름보다 역할로 구분하기

역할	이 논문의 선택
신경망 구조	Transformer 기반 MSAT / DiT
학습 목표	flow matching의 velocity 회귀
추론 생성	Euler 방법의 반복 갱신

t는 실제 로봇 시점, **τ**는 생성 중인 후보를 다듬는 denoising timestep이다.

현재 조건 아래 미래 후보를 만든다

$$c_t = [h_t, m_t, s_t, p_t]$$

$$a^\tau = \tau a + (1-\tau)\varepsilon$$

h·m은 cognition·memory, s·p는 현재 상태·센서다. **$a=a_{t:t+H}$**는 정답 행동 H+1개, ε는 같은 shape의 표준 정규 노이즈다.

$\tau=0$: 노이즈 ε

$\tau=1$: 정답 행동 a

학습에서는 정답으로 경로를 만들 수 있다. 모델이 배울 것은 그 경로의 변화율이다.

원문 설명·결과

변화율을 맞히도록 학습한다

선형 경로를 τ로 미분한 a−ε가 정답이며, 무작위 중간 점에서 그 값을 회귀한다.

Target과 학습 손실

$$d[\tau a+(1-\tau)\varepsilon]/d\tau$$
$$= a-\varepsilon = v^*$$

$$\mathcal{L} = \|u_\theta(a^\tau,\tau,c_t) - v^*\|_2^2$$

u_θ는 방향과 크기를 가진 **chunk 전체의 변화율**을 출력한다. L2 norm의 제곱은 좌표별 예측 오차 제곱을 합한 값이다.

숫자로 읽고, 학습 순서로 연결

2차원 설명용 예시

$$a=[3,-1],\ \varepsilon=[-1,1]$$
$$v^*=[4,-2]$$

예측이 [3.9,−1.8]이면 오차 제곱의 합은 **0.01+0.04=0.05**다.

학습은 **τ·ε 샘플링 → a^τ 구성 → 변화율 예측 → 손실·역전파**다. 매 샘플마다 완전한 denoising을 반복해야 하는 목표는 아니다.

학습은 무작위 중간 점에서 변화율을 맞히는 일이다. 추론은 그 변화율로 후보를 옮긴다.

원문 설명·결과

Euler 반복으로 미래 chunk를 완성한다

현재 조건을 고정해 참조하면서 미래 행동·센서 후보를 반복 갱신한다.

변화율 × 간격 = 이동량

$$\Delta\tau_i = \tau_{i+1} - \tau_i$$
$$a^{\tau_{i+1}} = a^{\tau_i} + \Delta\tau_i u_\theta(a^{\tau_i}, \tau_i, c_t)$$

한 좌표 예시 후보 0, 변화율 4, Δτ=0.25라면 다음 후보는 **0+0.25×4=1**이다.

노이즈에서 시작해 **변화율 예측** → **후보 갱신**을 τ=1까지 반복한다. 한 forward가 chunk 전체를 다룬다.

현재 센서와 미래 센서는 역할이 다르다

현재 p_t: 관측된 조건.
미래 $p^{\tau}_{t+1:t+L}$: 함께 denoising할 후보.

$$p^{\tau} = \tau p_{\text{future}} + (1-\tau)\varepsilon_p$$
미래 센서의 target: $p_{\text{future}} - \varepsilon_p$

미래 물리 신호 예측은 상호작용을 배우기 위한 **보조 목표**다. τ 반복은 실제 로봇 시간 t의 전진이나 재관측과 다르다.

현재 조건과 생성 후보를 분리했다. 다음은 이 입력들을 **MSAT** 안에서 어떻게 섞는가다.

원문 설명·결과

서로 다른 입력은 전용 stream으로

C·A·P는 전용 normalization·projection을 갖고, QKV를 모아 정보를 교환한다.

초반의 입력 배치

경로	입력
C	cognition h_t, memory m_t
A	현재 상태 s_t, 행동 후보 a^τ
P	현재 센서 p_t, 미래 후보 p^τ

τ 토큰은 A 앞에 놓인다. 물리 신호가 없으면 P stream의 attention을 mask할 수 있다.

전용 파라미터와 공통 attention

각 stream의 Norm → 각자의 QKV projection

Q·K·V를 각각 **토큰 축으로 concat**

joint self-attention으로 모달리티 간 정보 교환

고차원 cognition, 저차원 state, 희소한 센서 신호를 다루는 설계다. 정보를 교환해도 stream별 변환 파라미터는 구분될 수 있다.

전용 stream은 서로 보지 않는다는 뜻이 아니다. Attention 출력 위치를 따라 다시 나눈다.

원문 설명·결과

함께 읽고, 나눠서 갱신한다

Joint attention은 정보는 섞어도 query 위치 수를 유지하므로 출력을 stream별로 돌려보낼 수 있다.

C 4개 + A 3개로 보는 원리

실제 모델 shape가 아닌 예시



$$Q,K,V: 7\times d$$
$$\text{attention: } 7\times 7 \rightarrow \text{출력: } 7\times d$$

앞 4개 출력은 C, 뒤 3개는 A로 나눈다. 각 출력은 다른 stream의 정보를 이미 읽었을 수 있다.

Residual과 후반 concat은 다르다

$$C' = C + \Delta C,\ A' = A + \Delta A$$
$$\text{후반: } C\text{-}A = \text{concat}(C', A')$$

처음에는 각 stream에 보정을 더한다. **후반에는 C·A를 한 시퀀스로 통합**한다. 덧셈과 토큰 이어 붙이기를 구별해야 한다.

표기 불일치 앞 문단은 noisy action을 A에 배치하지만 마지막 물리 센싱 요약은 C라고 쓴다. 오타 여부는 미확인이다.

공통 attention, stream별 residual, 후반 C-A 통합은 서로 다른 단계다.

전체 구조에서 MSAT의 위치

VLM·memory가 조건을 준비하고, 공유 action model이 미래 행동과 센서 후보를 다듬는다.

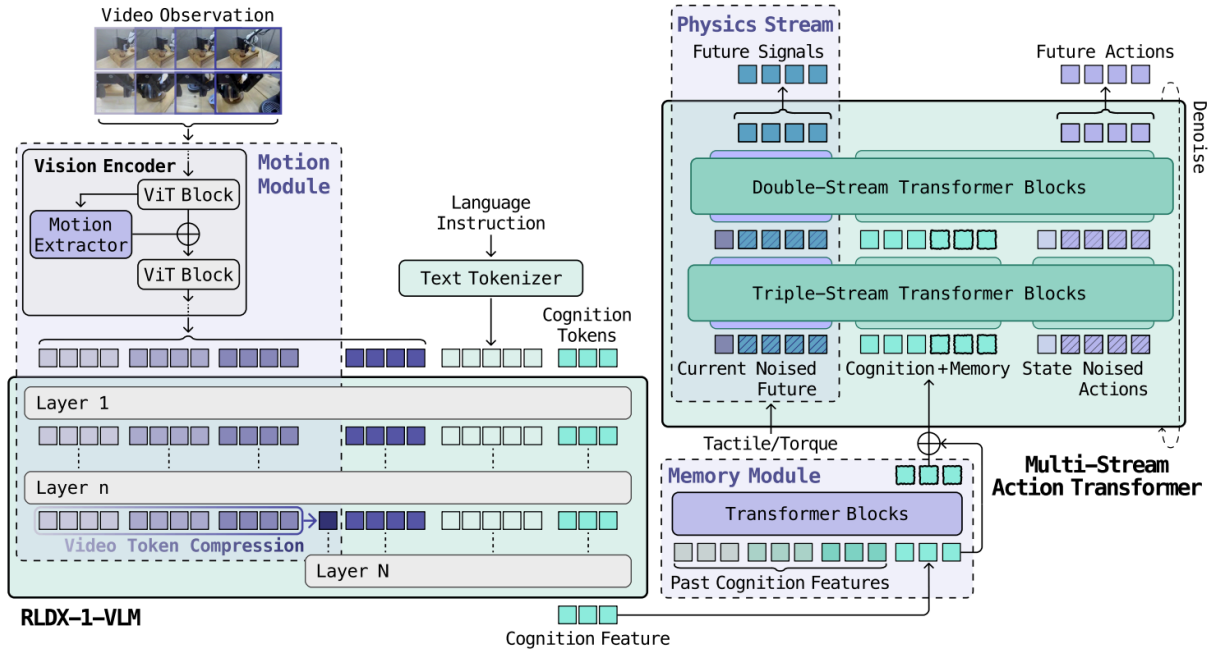


Figure 3 · motion·memory·physics를 연결한 RLDX-1 구조

분리·통합과 로봇별 연결

센서 있음: C/A/P → C-A/P

센서 없음: C/A → C-A

P는 물리 신호가 있을 때 독립 경로로 남아 C-A와 정보를 교환한다.

로봇별 input projection → **공유 MSAT** → 로봇별 output projection으로 서로 다른 state·action 공간을 연결한다.

새 embodiment용 공통 projection도 일부 샘플로 학습한다. P 경로와 로봇별 연결층은 서로 다른 분리 기준이다.

구조는 연결됐다. 입력 모달리티의 차이와 로봇 몸체의 차이는 서로 다른 경계에서 처리한다.

Fig.3 · PDF p.6; Sec.2.2 · PDF p.8; Sec.4.1 · PDF p.12

행동 생성에 맞춘 블록 설계

생성 진행도와 행동 순서를 구별해 주입하고, 정규화와 비선형 특징 변환을 더한다.

τ와 행동 위치는 다른 정보

> **τ:** sinusoidal embedding → MLP → A 앞의 한 토큰

> **행동 순서:** A stream에 RoPE 적용

τ 토큰은 joint attention으로 현재 denoising timestep을 전달한다. RoPE는 위치별 Q·K 회전을 통해 상대 시간 관계를 반영한다. 둘 다 행동을 한 개씩 생성하도록 강제하는 규칙은 아니다.

특징 크기와 토큰 내부 변환

RMSNorm: 특징을 평균 제곱 크기로 정규화한다. query·key에도 적용한다.

$$\mathrm{RMS}(x)=\sqrt{(\Sigma x_j^2/d)}$$
$$g=\mathrm{SiLU}(xW_g),\ v=xW_v$$
$$\mathrm{FFN}(x)=(g \odot v)W_o$$

SwiGLU: 비선형 gate와 다른 특징을 원소별로 곱한다. Attention의 토큰 간 정보 교환과 달리, FFN은 토큰 내부 특징을 바꾼다.

> **무엇을 생성할지와 어떻게 처리할지 이해했다. 다음은 이 구조를 채운 데이터와 학습이다.**

경험을 넓히고, 부족한 상황을 합성한다

공개·자체 데이터의 강점을 연결하고, 합성 영상에 행동 라벨을 붙여 경험을 확장한다.

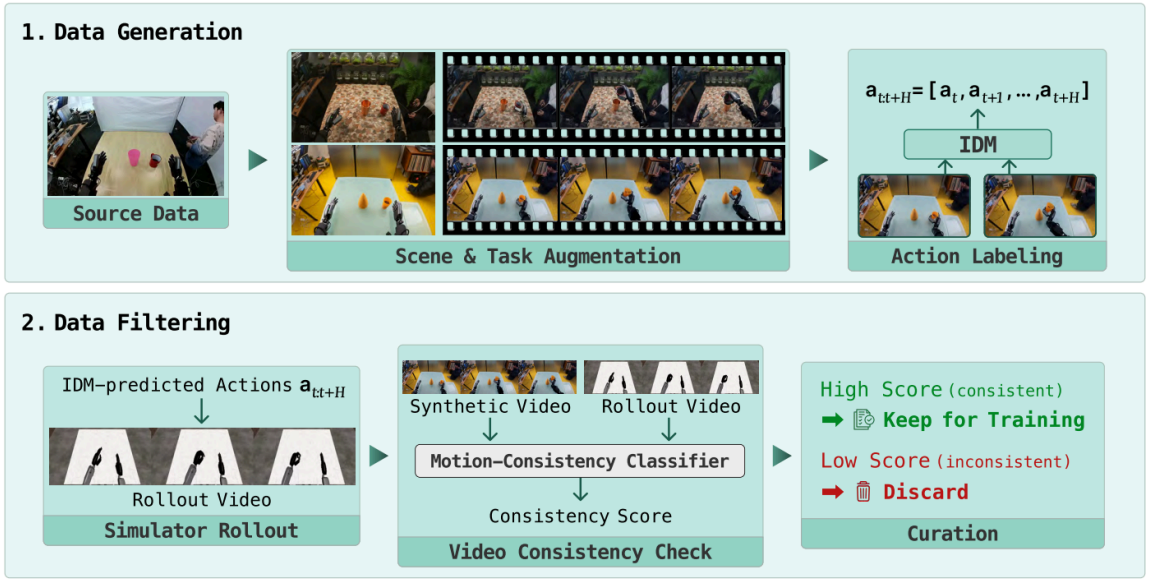


Figure 4 · 생성 영상에 행동을 붙이고 두 단계로 검사하는 파이프라인

세 공급원의 역할

공개 데이터는 다양한 로봇의 조작 경험을, **자체 데이터**는 Franka·ALLEX의 고유 제어와 토크·촉각을 제공한다. 사람의 원격 조작을 수치 행동과 센서 기록으로 연결한다.

합성 데이터는 수집이 어려운 장면을 늘린다. 지시·장면 변형 → 영상 생성 → IDM 행동 라벨링 → 검증의 흐름이다.

> Task는 목표 지시, action은 로봇을 움직이는 수치다. 영상과 행동이 맞는지 별도로 확인한다.

데이터를 늘리는 것과 학습 가능한 영상–행동 쌍을 만드는 것은 함께 해결해야 한다.

작업과 장면을 함께 다양화한다

지시의 변형과 시각적 변형을 나누되, 원본 장면에서 가능한 동작을 유지하려 한다.

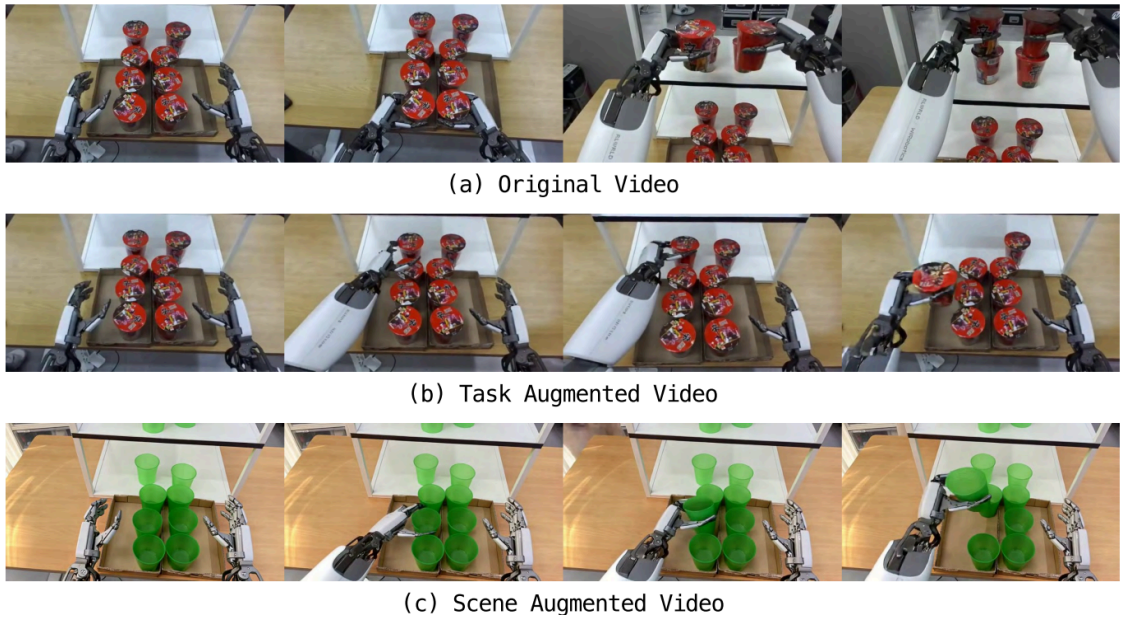


Figure 5 · (a) 원본 (b) 지시 변형 (c) I2I 편집 후 I2V 생성

무엇을 할지, 어디에서 할지

Task: 행동·물체·위치·손을 재조합하거나 원본 skill을 조건으로 변형한다. 두 전략의 결과는 겹칠 수 있다.

Scene: 시작 장면을 I2I로 편집해 I2V로 생성하거나, V2V로 영상의 색·질감을 바꾸며 움직임을 보존하려 한다.

> Canny edge는 구조 보존을 유도한다. 실행 가능성을 보장하지 않으며, 구체적인 판정 규칙·prompt는 미확인이다.

> **Figure 5(c)는 I2I→I2V 예시다. V2V만의 효과를 보여주는 비교는 아니다.**

영상이 그럴듯해도 행동 라벨은 검사한다

IDM의 추정 행동을 시뮬레이터에서 재생하고, 생성 영상의 움직임과 비교한다.

영상에서 행동으로

관측 쌍 → IDM → 추정 행동

현재·미래 프레임에서 중간 행동을 추정해 pseudo-label을 만든다. 그 행동을 simulator에서 재생하면 비교용 rollout 영상이 생긴다.

별도 품질 VLM은 지시 불일치를 re-caption하고, 동작 plausibility를 평가해 선별한다.

움직임이 서로 맞는가?

두 clip을 frozen V-JEPA2로 인코딩하고 특징을 concat한다. 학습 가능한 query가 cross-attention으로 읽은 뒤 linear head가 일치를 판별한다.

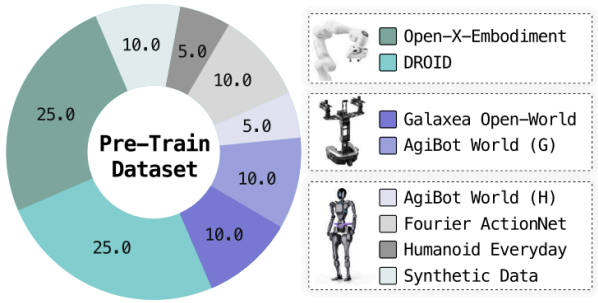
실제 clip+GT 행동 rollout은 positive, 시간·episode가 어긋난 쌍은 negative다.

> 필터 통과는 현실의 물리적 성공 보장이 아니다.
> 검사기의 정량 신뢰성은 추가 검증이 필요하다.

영상 품질과 영상–행동 정합성은 서로 다른 검증 대상이다.

범용 조작을 배우고 새 로봇 적응을 준비한다

Pre-training의 공통 경험을 출발점으로 mid·post-training에서 적응 범위를 좁힌다.



Dataset	Embodiment	End-Effector	Episodes
Open-X-Embodiment	Single-arm	Gripper	870K
DROID	Single-arm	Gripper	92K
Galaxea Open-World	Dual-arm	Gripper	114K
AgiBot World (G)	Humanoid	Gripper	239K
AgiBot World (H)	Humanoid	Hand	36K
Fourier ActionNet	Humanoid	Hand	30K
Humanoid Everyday	Humanoid	Hand	9K
Synthetic Data	Humanoid	Hand	150K
Total			**1.5M**

Figure 6 · 약 1.5M episode의 pool과 별도로 정한 학습 혼합 비중

세 단계의 역할

Pre: 다양한 로봇의 조작 → **Mid:** 특정 로봇·기능 확장 → **Post:** 목표 작업 적응.

Pre-training은 네 프레임을 입력해 flow matching으로 배운다. 로봇별 projection과 함께, batch의 일부 256 trajectory를 공통 projection으로 보내 새 로봇 적응의 초기값을 준비한다.

> Figure 6의 원은 학습 혼합 비중, 표는 episode pool 크기다. OXE와 DROID의 비중은 각 25%다.

공유 행동 모델과 공통 입출력 경로를 함께 학습해 embodiment 간 경험을 연결한다.

새 기능은 기존 정책에 단계적으로 맞춘다

Mid-training은 ALLEX·Franka 특화와 움직임·기억·물리 센싱의 확장을 함께 수행한다.

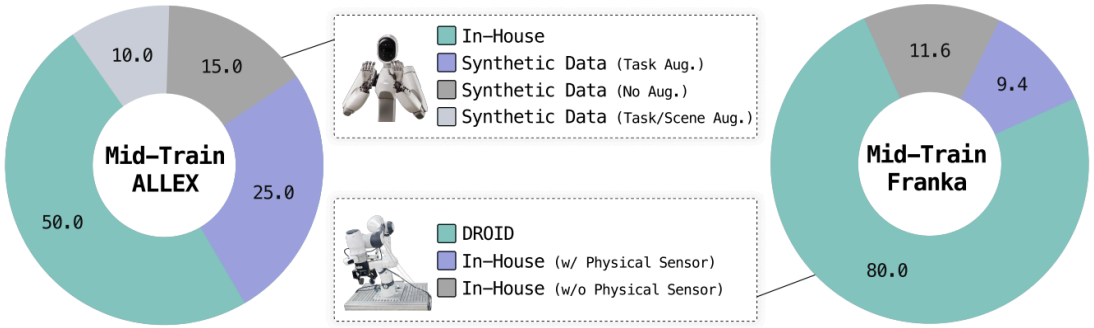


Figure 7 · 로봇별 데이터 혼합과 새 입력의 자체 데이터 supervision

기능을 추가하고 정렬하기

STSS로 움직임을, cognition queue로 기억을 보강한다. 토크·Franka 촉각을 입력하고 미래 센서도 예측한다.

처음 **2K alignment steps**는 새 파라미터만 학습하고, 이후 전체를 함께 갱신한다. 확장 입력 dropout과 physics의 near-zero 출력 초기화도 쓴다.

> 설정별 효과는 미확인이다. Franka 비율 합101%도 임의 보정하지 않는다.

여러 프레임은 pre-training부터 쓰고, 전용 기능 모듈은 mid-training에서 추가한다.

목표 작업은 시연과 실패에서 구체화한다

Post-training의 기본은 작업별 모방학습이며, 실패 조건에 맞춰 시연을 추가한다.

Base data: 일관성과 다양성

작업을 접근·잡기·이동·놓기 같은 동작으로 나누고 시연 시나리오를 정한다.

고정할 축

잡는 자세·경로·순서

변화시킬 축

물체 위치·자세·초기 상태

일관된 state–action 구조 안에 필요한 변화를 담아 제한된 시연을 수집한다.

Refinement: 실패를 다음 수집으로

> 시연으로 학습 → 실제 작업에 배치

> 실패 조건 관찰 → 추가 시연 → 재학습

예를 들어 새 물체 위치에서 실패하면 시연의 공간 범위를 넓힌다.

> 대부분 실험은 IL을 쓴다. 일부 어려운 조작에서 RECAP 기반 RL을 보완적으로 추가한다.

> **Post-training**이라는 단계 이름만으로 모든 작업에 **RL**이 적용됐다고 해석하지 않는다.

Critic의 평가를 다시 정책 학습으로 돌린다

별도 Gemma critic의 숫자 텍스트 value를 활용해 RECAP의 policy 개선을 반복한다.

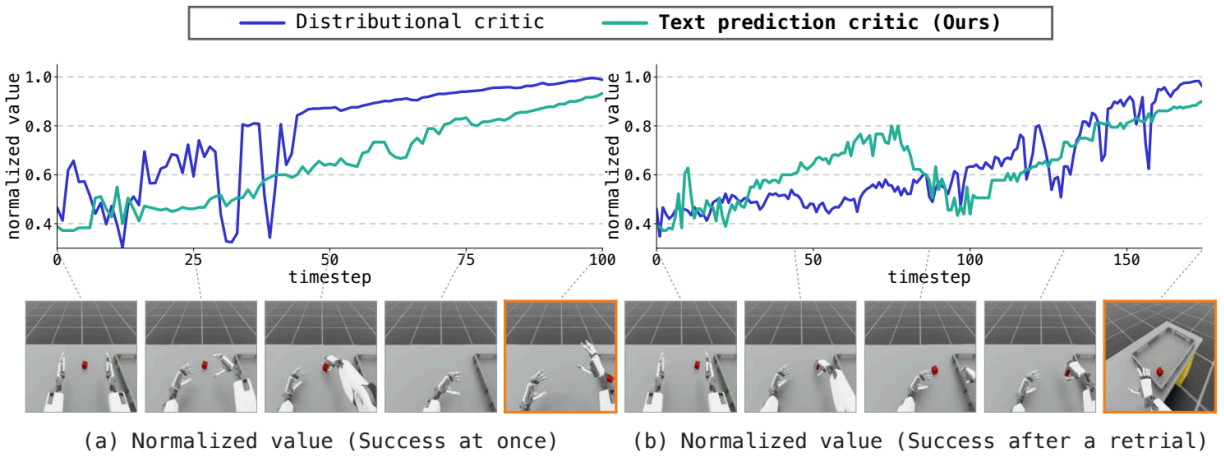


Figure 8 · 정규화 value가 진행·실패·회복을 따라가는 두 사례

평가 → 학습 → 새 경험

Critic은 Gemma3-4b-it으로 value를 숫자 텍스트로 예측한다. 행동을 만드는 Qwen 기반 RLDX-1과 별도 모델이다.

Critic → advantage labels → policy 학습 → rollout 수집을 반복한다. 성공 데이터로 critic을 갱신한다. 정확한 advantage label 식은 미기재다.

> 곡선은 성공률이 아닌 진행 value다. RECAP은 40 action을 생성해 20개 실행하며, 이는 denoising 횟수와 다르다.

실패·회복을 읽는 critic과 행동을 만드는 policy를 분리하고, 새 데이터로 함께 개선한다.

변하지 않는 준비 계산을 실행 밖으로 옮긴다

관측이 오래되기 전에 응답하려면 계산량뿐 아니라 GPU 호출 비용도 줄여야 한다.

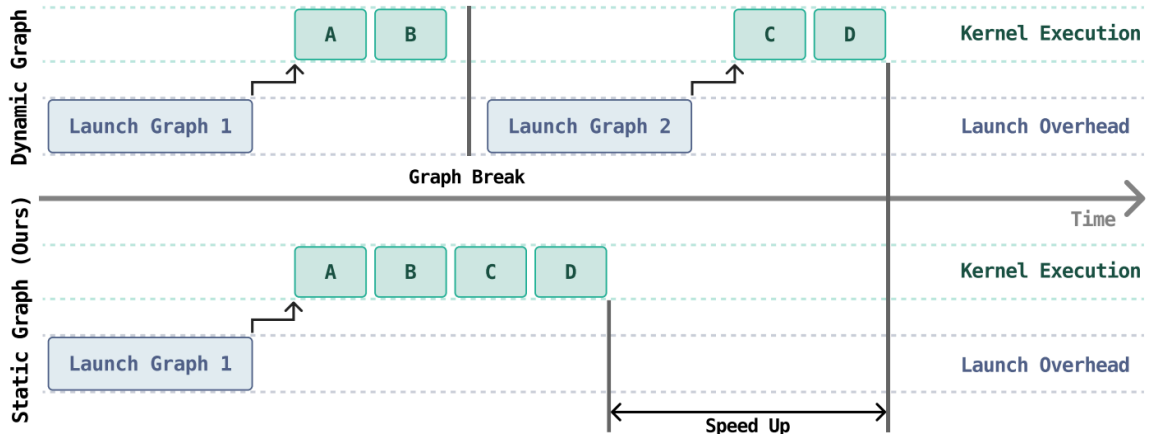


Figure 9 · 쪼개진 graph의 launch 비용을 줄이는 static graph capture

여러 호출에서 하나의 graph로

추론 중에도 장면은 변한다. 고정 배포 설정의 RoPE 준비 값·attention mask를 미리 계산하면 graph break를 줄여 forward를 한 CUDA Graph로 포착할 수 있다.

입력에 따른 Q/K·attention 계산은 계속 필요하다. 한 graph에 여러 kernel이 들어가며 denoising도 반복한다.

> Policy·LLM의 prefill은 입력을 함께 처리한다. 출력 토큰 순차 생성과 구분한다.

Graph capture는 행동의 의미보다 GPU에 연산을 제출하는 방식을 바꾼다.

원문 설명·결과

연산 사이의 메모리 왕복도 줄인다

Kernel fusion은 빠른 개별 연산들을 연결하는 데이터 흐름까지 함께 최적화한다.

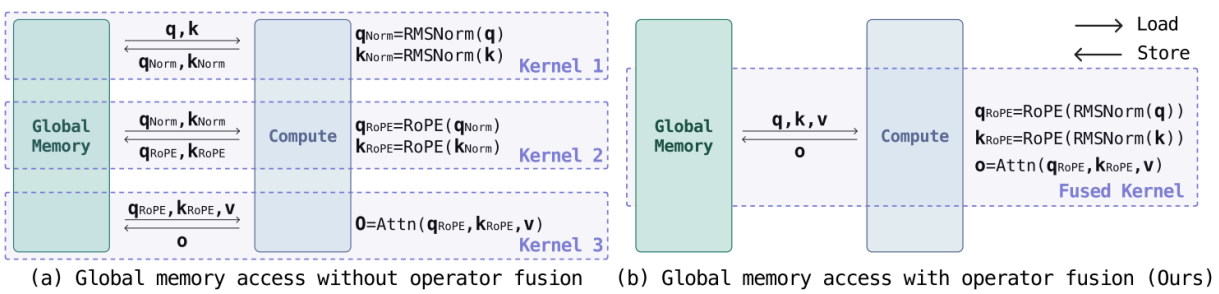


Figure 10 · 분리된 kernel의 global-memory 왕복과 fusion의 on-chip 재사용

계산과 이동의 두 병목

계산 병목의 matmul과 데이터 이동 병목의 RMSNorm·RoPE 등이 섞인다. **Memory-bound**는 대역폭 병목이며 OOM과 다르다.

Compiler의 fusion 경로와 외부 FlashAttention 경계가 남긴 중간 Q/K 저장·재읽기를 줄이도록, profiling한 일부 연산을 직접 묶는다.

> RMSNorm → RoPE → Attention을 묶어 중간 결과를 on-chip에 둔다. 나머지는 Torch Compile을 쓴다.

Attention 내부 최적화와 주변 연산을 아우르는 fusion은 서로 다른 최적화 경계다.

원문 설명·결과

범용 조작 평가: 상대 우위와 남은 난도

각 benchmark에 적응한 전체 시스템은 높은 성과를 냈지만 복합 조작은 여전히 어렵다.

평가 (%)	최강 baseline	RLDX-1
LIBERO 평균	96.9	97.8
LIBERO-Plus	86.5	86.7
GR-1 Tabletop	48.0	58.7
RC365 전체 / 미지 복합	26.9 / 4.4	32.1 / 5.6

Pre-trained 모델을 각 benchmark에 fine-tuning한다. Baseline은 π0-FAST·π0·π0.5·GR00T N1.5/N1.6이며 재현값과 논문·저장소·leaderboard 수치가 섞여 있다.

해석 전체 recipe의 성과다. 특정 모듈의 독립 효과나 작은 차이의 통계적 유의성을 이 표만으로 확정할 수 없다.

> **높은 순위와 낮은 절대 성공률을 함께 읽는다.**

Sec.6–6.1 · Table 1 · PDF pp.17–19; App.G.1 · PDF pp.48–49

원문 설명·결과

OpenArm: 지시와 새 상황으로의 일반화

같은 물체 옮기기도 위치 지시·새 개체·새 배치·instance 선택으로 나눠 평가한다.

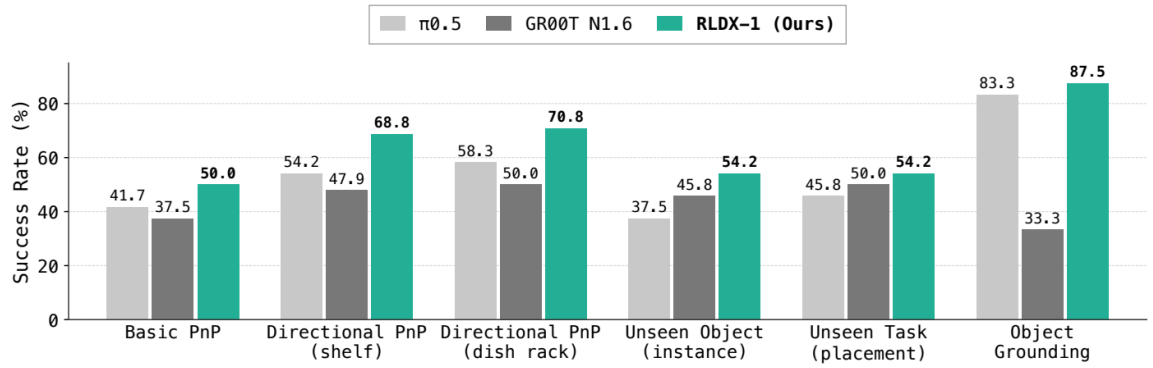


Figure 14 · OpenArm의 여섯 평가 설정

기본 물체 옮기기에서 지정 칸에 놓기, 새 개체·새 배치, 같은 종류 중 언어가 지정한 instance 선택까지 확장한다.

RLDX-1은 선반 68.8%·식기대 70.8%, 새 개체·새 작업 각 54.2%, grounding 87.5%다. 보통 24회, 선반은 48회다.

Grounding은 올바른 물체 잡기, 나머지는 지정 위치에 놓기가 성공이다. 저자 해석 과적합·grounding 실패라는 설명은 원인별 통제 결과가 아니다.

미지 개체·작업에서도 우위가 있으나 기본 조작의 실패도 남는다.

ALLEX: 움직임·기억·물리 피드백

컨베이어·숨긴 상자·카드·따르기로 서로 다른 기능을 시험한다.

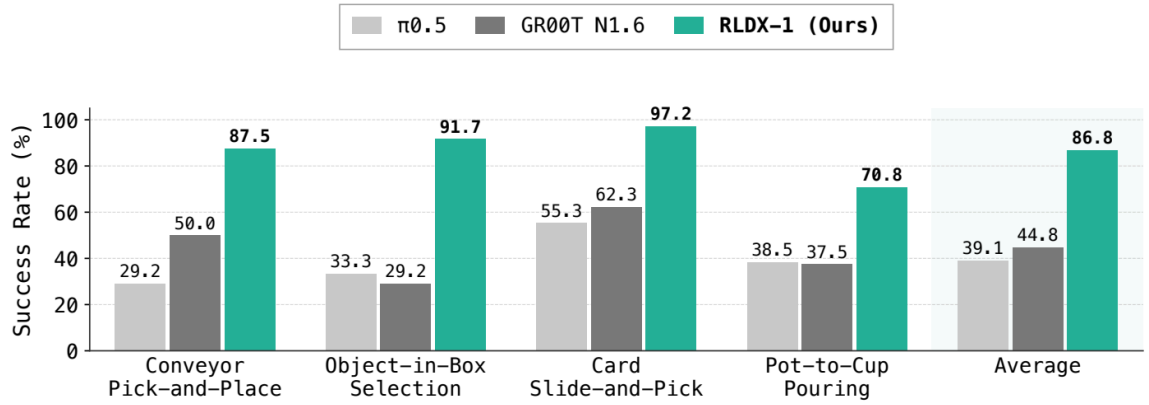


Figure 16 · 성공률과 progress score가 함께 표시된 결과

움직임: 학습한 양 끝 속도 사이의 새 속도에 맞춰 상자를 잡는다. **기억:** 물체를 넣어 둔 상자를 과거 관찰로 고른다.

물리 피드백: 카드를 밀고 잡아 건네며, 플라스틱 공을 따를 때 컵 무게 변화에 맞춰 멈춘다. 실제 액체 평가가 아니다.

컨베이어 87.5%·상자 91.7%는 성공률이다. 카드 97.2·따르기 70.8은 부분 완료를 포함한 진행 점수다.

평균 86.8은 혼합 지표

네 과제의 완전 성공률 평균으로 소개하면 안 된다.

같은 0–100 눈금이라도 성공률과 진행 점수의 의미는 다르다.

원문 설명·결과

Franka: 다른 몸체에서도 나타난 기능별 개선

회전·Pong·컵 기억·접촉 과제로 확장했지만 정밀 조작의 성공률은 아직 낮다.

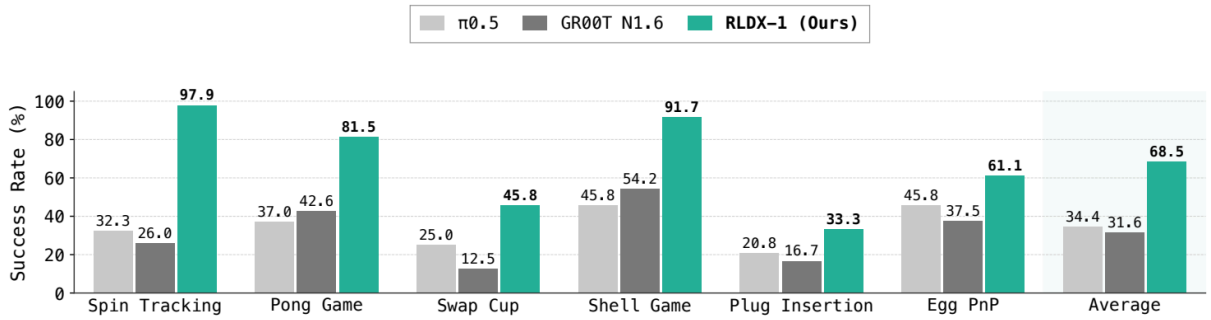


Figure 18 · Franka 기능별 성공률과 남은 어려움

회전·Pong은 움직임, Cup·Shell은 기억, Plug·Egg는 접촉을 시험한다. Spin 97.9%·Shell 91.7%에 비해 Cup 45.8%·Plug 33.3%에는 많은 실패가 남는다.

Franka는 torque·AnySkin을 쓴다. ALLEX·Franka 모두 과제 관련 모듈만 켜므로 세 기능의 동시 시너지나 각 모듈의 독립 효과는 분리되지 않는다.

Q13 Spin96·Pong54회, 나머지24회다. Egg61.1%와24회 이진 성공률의 대응은 불명확하다.

기능별 우위를 유지하되 낮은 절대 성공률·활성화 조건·분모를 함께 밝힌다.

원문 설명·결과

Ablation: 표현 선택과 합성 규모의 근거

바꾼 요소와 고정 조건을 확인하면 관측된 효과와 저자의 원인 설명을 나눌 수 있다.

분석	보고 성공률 (%)	읽을 범위
VLM 추출 층 8 / 18 / 28	51.1 / 60.9 / 56.3	세 후보 중18층 우세
Robot VQA 적응	57.5 → 60.9	+3.4%p
합성 pool 0 → 100%	41.0 → 50.1	+9.1%p

층·VQA는 Kitchen의 별도 base 설정이다. 합성은 GR-1의 실제 데이터를 고정하고 pool 25·50·100%를 비교하며, 합성이 있는 조건의 실제:합성 sampling은 모두 1:1이다.

한계 Figure19는 마지막 prompt token의 patch attention 예시다. 인과 증명이 아니며 task/scene 증강·필터 각각의 효과도 이 비교에서 분리되지 않는다.

> 관측한 비교를 넘어 메커니즘과 개별 단계의 기여를 자동으로 확정하지 않는다.

RL은 완료 효율을, 최적화는 실행 지연을 줄였다

전구 과제의 frames·attempts와 policy p50은 서로 다른 효율 지표다.

전구 비틀기: BC → RECAP3

완료 frames는 1056±326→353±22, 비튼 횟수는 12.7±3.0→4.1±0.3으로 약 3배 줄었다. 성공률 표가 아니며 추가 rollout·학습도 늘어나 RL objective만의 효과는 분리되지 않는다.

All-modality 추론 stack의 누적 최적화

Eager	Graph+Compile	+Static	+Kernel
71.2ms	59.6ms	48.9ms	43.7ms

최종 1.63배는 Eager 대비 누적값이며, 마지막 kernel 단계만은 1.12배다. RTX5090, dual-view192×256·4frames·Euler4회에서 측정한 policy p50이며 카메라→모터 전체 지연은 아니다.

> **빠른 완료·빠른 policy 호출과 높은 성공률·안정적인 전체 제어는 구별한다.**

우리 해석

부록: 확장이 항상 같은 이득을 주는가?

적응 비용·후보 탐색·합성 보강·학습 예산은 각각 다른 절충과 확인 과제를 남긴다.

① PEFT의 비용 절충

Top-4 VLM full FT+action LoRA64는 62.67%를 유지한다. 양쪽 LoRA64는 55.33%·batch1 VRAM 23.71GiB다. 실제 측정 GPU는 H200이다.

② Best-of-N의 조건부 이득

N8/T1.5는 RECAP1의 attempts를 8.5→4.9로 줄이지만 RECAP2·3는 악화한다. 별도 frozen-feature Q critic이며 Gemma critic과 다르다.

③ Table9의 합성·집계

잡기 완전 성공 count는 9/24→14/24다. 보고 점수는 66.7→83.3이지만 count에 1/0.5/0을 적용한 합은 13·18로, 보고 16·20과 다르다.

④ Batch·평균의 함정

GR-1은 batch64→1024에서 36.8→58.7이다. 총 노출 예산 통제는 불명확하다. 높은 평균에도 camera75.0, stove off22.0, 복합 과제0%가 남는다.

비용·집계·평가 예산까지 살펴야 확장의 성과와 적용 범위가 보인다.

우리 해석

연구의 위치: 기능을 실용 시스템으로 연결한다

저자는 VLA·영상 합성·기능별 연구를 통합한 로봇 정책으로 제시한다.

세 연구 흐름의 연결

언어 조건 행동을 생성하는 VLA에 multi-frame·memory queue·물리 신호를 더하고, 영상 생성+IDM 합성 데이터와 3단계 학습·실행 최적화를 함께 설계한다.

저자 주장 범용성뿐 아니라 움직임·기억·접촉을 다루는 기능이 실제 조작에 필요하며 이를 통합했다는 것이 차별점이다.

실험이 지지하는 범위

여러 benchmark와 실제 로봇의 기능별 과제에서 높은 보고값을 얻었다. 그러나 통합 구조의 성과와 각 구성 요소의 독립 기여는 다르다.

우리의 정리 유망한 시스템 통합이지만 긴 복합 작업·정밀 접촉·집계 재현·지연 꼬리에는 확인할 것이 남는다. 마지막에는 그 열린 질문을 모은다.

성과는 구체적인 조건에서 확인하고 일반화의 범위는 근거에 맞춰 남겨 둔다.

미해결 질문

열린 질문: 명세·집계·독립 기여

원문 값을 임의로 고치지 않고 확인된 불일치와 필요한 후속 근거를 남긴다.

위치	확인된 불일치	필요한 근거
Q11 · Fig.7	Franka 비중 합101.0 vs 본문8:2	혼합 설정
Q12 · Table8	RC365 batch196 vs192	실행 설정
Q13 · Fig.18	Egg61.1% vs24회 설명	분모·집계법
추가 · Table9	Count 가중합13/18 vs 보고16/20	Count·점수 명세

운영·생성 Memory 갱신·초기화, H/H+1·C/A 표기, skill 목록·실행 가능성 규칙은 더 확인해야 한다.

후속 실험 모듈·필터·RL의 독립 비교, 동일 데이터·compute 예산, 평가 불확실성, end-to-end p95/p99가 결론을 더 선명하게 한다.

> 불확실성을 숨기지 않고 다음 검증의 출발점으로 남긴다.